



温州大學
WENZHOU UNIVERSITY

深度学习-生成式深度学习

黄海广 副教授

2023年06月

- 01** 生成式深度学习简介
- 02** **GAN**的理论与实现模型
- 03** **GAN** 的应用
- 04** **GAN**的思考与前景

1.生成式深度学习简介

3

01 生成式深度学习简介

02 GAN的理论与实现模型

03 GAN 的应用

04 GAN的思考与前景

1.生成式深度学习简介


4

- 深度学习中常见生成式模型
 - 自编码 (AE)
 - 其隐变量 z 是一个单值映射: $z=f(x)$
 - 变分自编码 (VAE)
 - 其隐变量 z 是一个正态分布的采样
 - 生成式对抗网络 (GAN)
 - 条件生成式对抗网络 (CGAN)
 - 在生成器和判别器中添加某一标签信息
 - 深度卷积生成式对抗网络 (DCGAN)
 - 判别器和生成器都使用了卷积神经网络 (CNN) 来替代GAN 中的多层感知机
 - 为了使整个网络可微, 拿掉了CNN 中的池化层
 - 将全连接层以全局池化层替代以减轻计算量。

1.生成式深度学习简介

5

自编码 (AE) 结构图



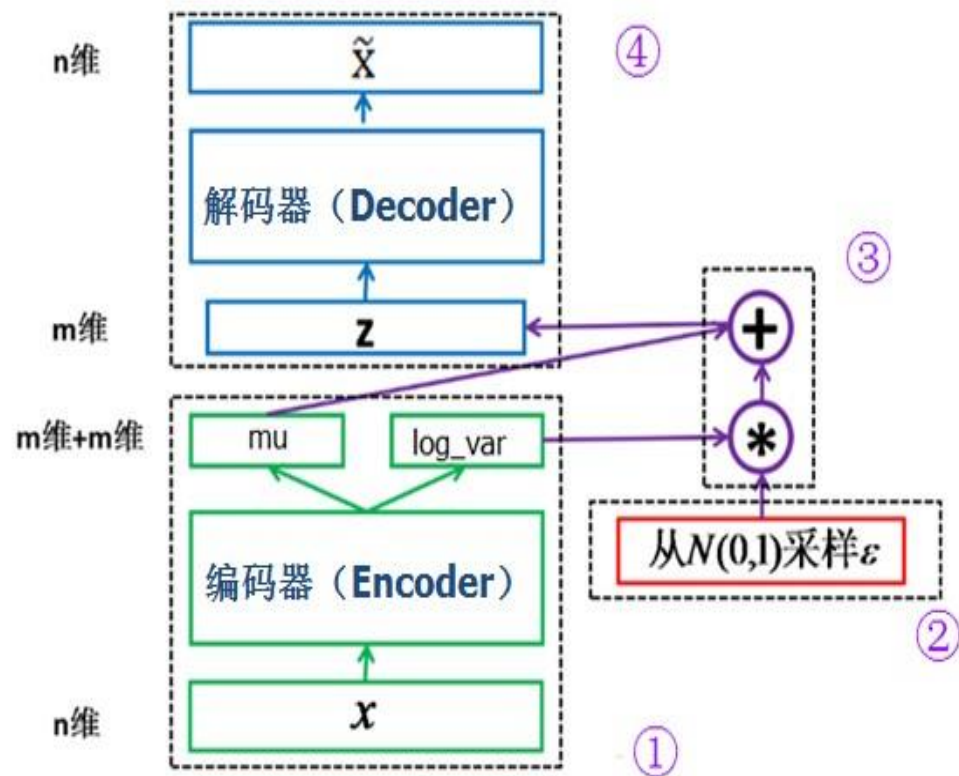
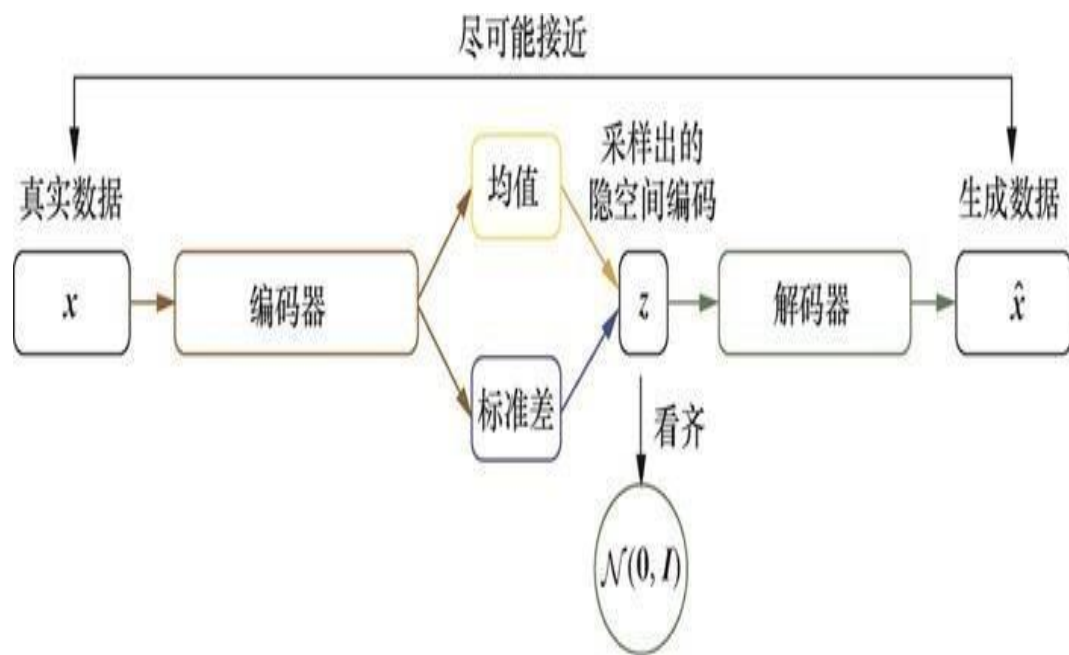
损失函数:

$$L_{AE} = \mathbb{E}_{x \sim \tilde{p}(x)} [\|x - \hat{x}\|^2] = \mathbb{E}_{x \sim \tilde{p}(x)} [\|x - D(E(x))\|^2]$$

1.生成式深度学习简介

6

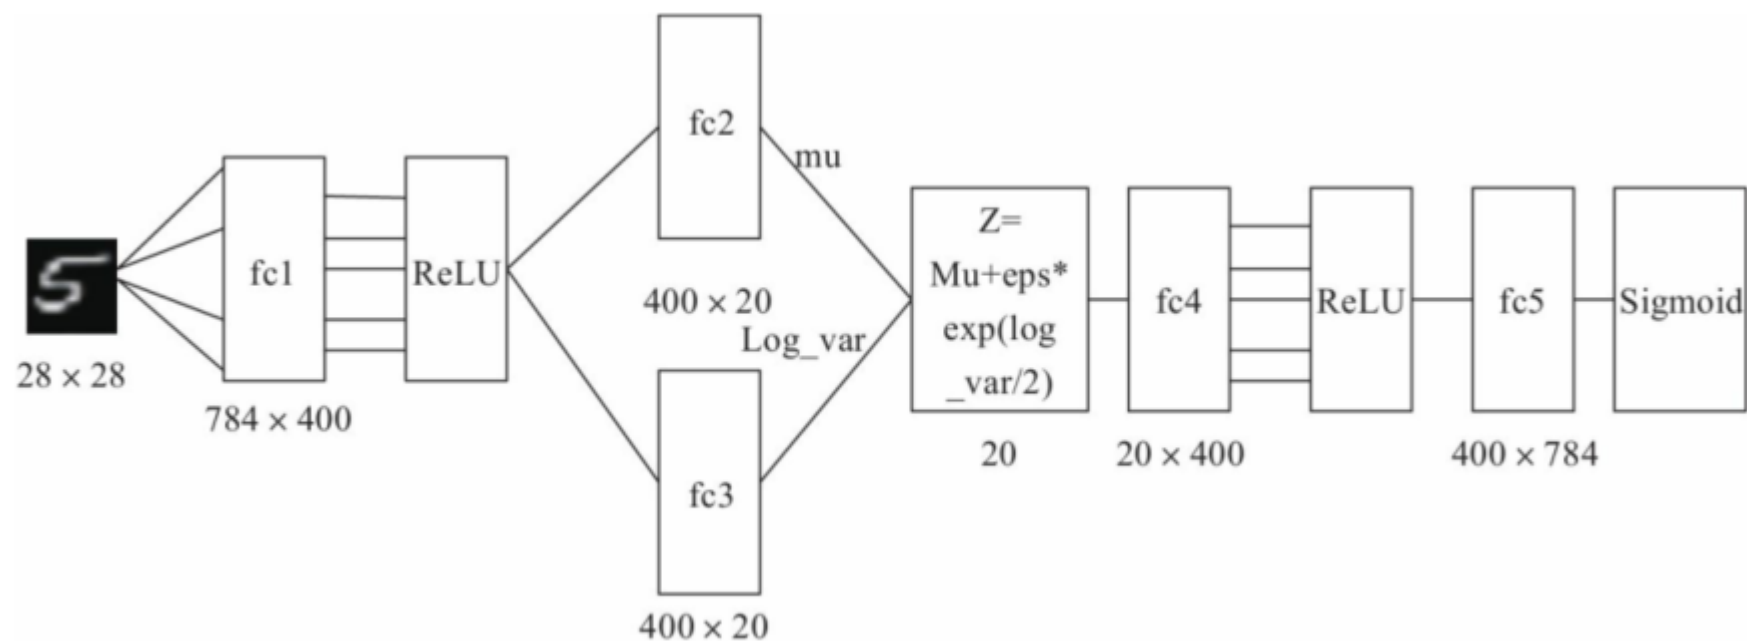
变分自编码 (VAE) 结构图



1.生成式深度学习简介

7

变分自编码 (VAE) 生成图像



2. GAN的理论的实现模型

8

01 生成式深度学习简介

02 **GAN**的理论的实现模型

03 **GAN** 的应用

04 **GAN**的思考与前景

2. GAN的理论的实现模型

9

概念简介

提出背景

GAN (**Generative Adversarial Networks**)，中文翻译为**生成式对抗网络**，是 Ian Goodfellow 等在2014 年提出的一种生成式模型。

GAN的基本思想源自博弈论的二人零和博弈, 由一个生成器和一个判别器构成, 通过对抗学习的方式来训练. 目的是估测数据样本的潜在分布并生成新的数据样本。

2. GAN的理论的实现模型

10


概念简介

提出背景

2001年, Tony Jebara
在毕业论文中以最大熵
形式将判别模型与生成
模型结合起来联合学习

2012年, Jun Zhu 将最大间隔机
制与贝叶斯模型相结合进行产生
式模型的学习。

起源



发展

2007年, Zhuowen Tu 提出将基
于boosting分类器的判别模型与
基于采样的生成模型相结合, 来
产生出服从真实分布的样本。

2014年, Ian Goodfellow 等人
提出生成式对抗网络, 迎合了
大数据需求和深度学习热潮,
给出了一个大的理论框架及理
论收敛性分析。

2. GAN的理论的实现模型

11

概念简介

提出背景

- (一) 人工智能的热潮
- (二) 生成式模型的积累
- (三) 神经网络的深化
- (四) 对抗思想的成功

2. GAN的理论的实现模型

12

GAN的基本原理

GAN的学习方法

GAN的衍生模型

2. GAN的理论的实现模型

13

GAN 的核心思想来源于博弈论的**纳什均衡**。

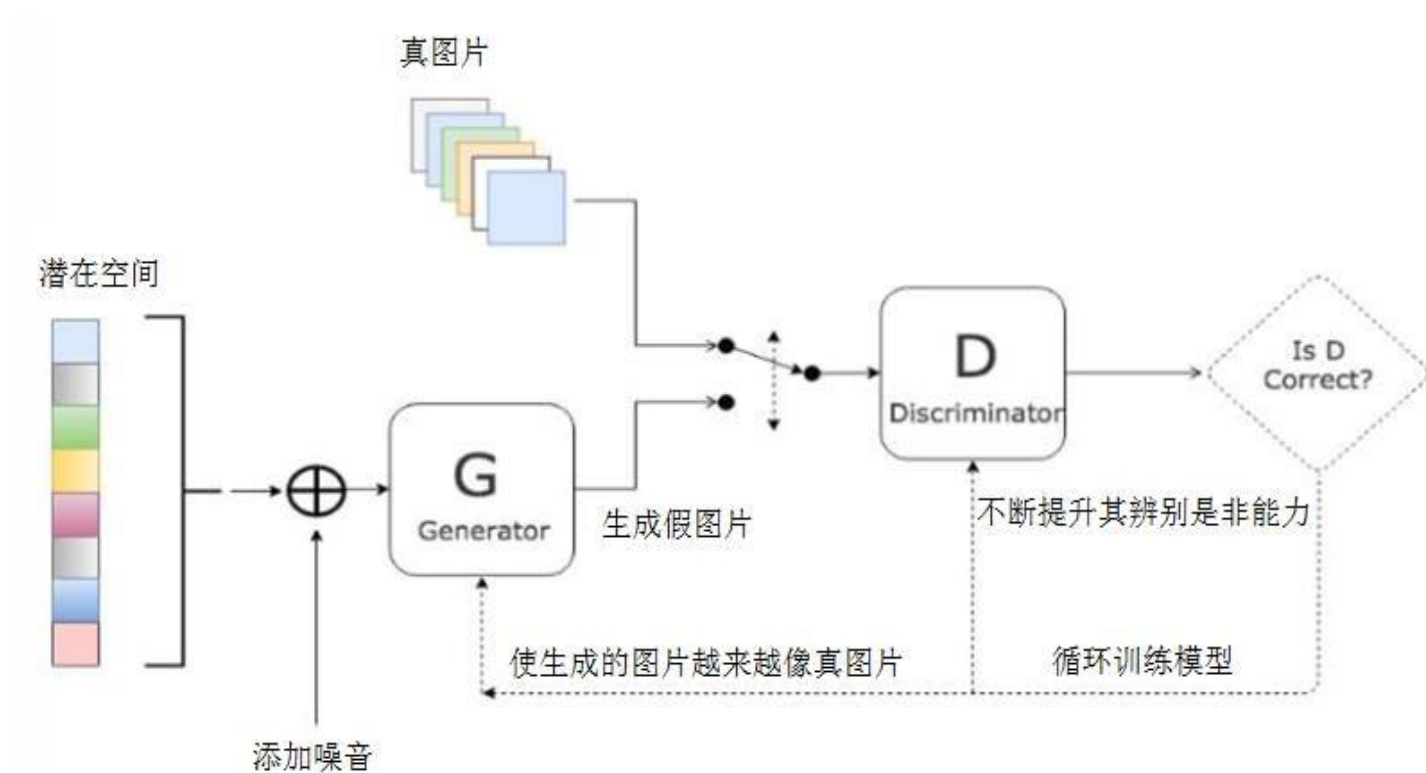
它设定参与游戏双方分别为一个生成器 (Generator) 和一个判别器(Discriminator)，生成器的目的是尽量去学习真实的数据分布，而判别器的目的是尽量正确判别输入数据是来自真实数据还是来自生成器；为了取得游戏胜利，这两个游戏参与者需要不断优化，各自提高自己的生成能力和判别能力，这个学习优化过程就是寻找二者之间的一个**纳什均衡**。



2. GAN的理论的实现模型

14

生成式对抗网络（GAN）结构图



2. GAN的理论的实现模型

15

GAN的学习方法

首先, 在给定生成器 G 的情况下, 我们考虑最优化判别器 D .

$$Obj^D(\theta_D, \theta_G) = -\frac{1}{2}E_{x \sim p_{data}(x)}[\log D(x)] - \frac{1}{2}E_{z \sim p_z(z)}[\log(1 - D(g(z)))] \quad (1)$$
$$D_G^*(x) = \frac{p_{data}(x)}{p_{data}(x) + p_g(x)} \quad (4)$$

$$Obj^D(\theta_D, \theta_G) = -\frac{1}{2} \int_x p_{data}(x) \log(D(x)) dx - \frac{1}{2} \int_z p_z(z) \log(1 - D(g(z))) dz =$$
$$-\frac{1}{2} \int_x [p_{data}(x) \log(D(x)) + p_g(x) \log(1 - D(x))] dx \quad (2)$$
$$\min_G \max_D \{f(D, G) = E_{x \sim p_{data}(x)}[\log D(x)] + E_{z \sim p_z(z)}[\log(1 - D(G(z)))]\} \quad (5)$$

$$-m \log(y) - n \log(1 - y) \quad (3)$$

2. GAN的理论的实现模型

16

GAN的学习方法

总之, 对于 GAN 的学习过程, 我们需要训练模型 D 来最大化判别数据来源于真实数据或者伪数据分布 $G(z)$ 的准确率, 同时, 我们需要训练模型 G 来最小化 $\log(1 - D(G(z)))$.

这里可以采用交替优化的方法: 先固定生成器 G, 优化判别器 D, 使得 D 的判别准确率最大化; 然后固定判别器 D, 优化生成器 G, 使得 D 的判别准确率最小化. 当且仅当 $p_{data} = p_g$ 时达到全局最优解. 训练 GAN 时, 同一轮参数更新中, 一般对 D 的参数更新 k 次再对 G 的参数更新 1 次.

2. GAN的理论的实现模型

17

GAN的衍生模型

CGAN

DCGAN

**Info
GAN**

.....

WGAN

EBGAN

**Improved
GAN**

2. GAN的理论的实现模型

18

GAN的衍生模型

(1) CGAN--条件生成对抗网络，为了防止训练崩塌将前置条件加入输入数据。

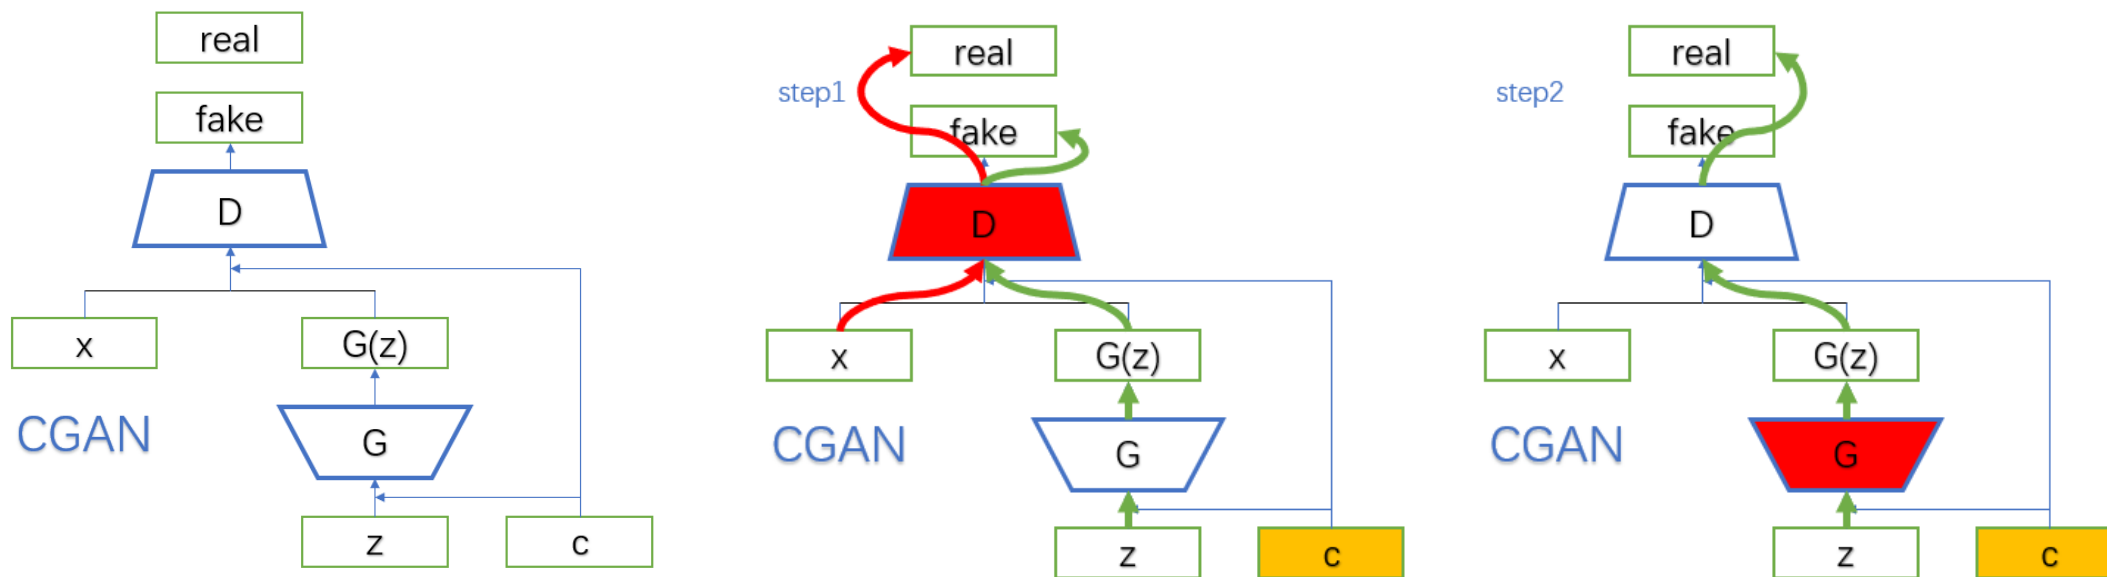


图 条件生成对抗网络的结构

2. GAN的理论的实现模型

19

GAN的衍生模型

(2) DCGAN--深度卷积生成对抗网络，提出了能稳定训练的网络结构，更易于工程实现。




图 深度卷积生成对抗网络的结构

2. GAN的理论的实现模型

20

GAN的衍生模型

(3) InfoGAN--信息最大化生成对抗网络，通过隐变量控制语义变化。

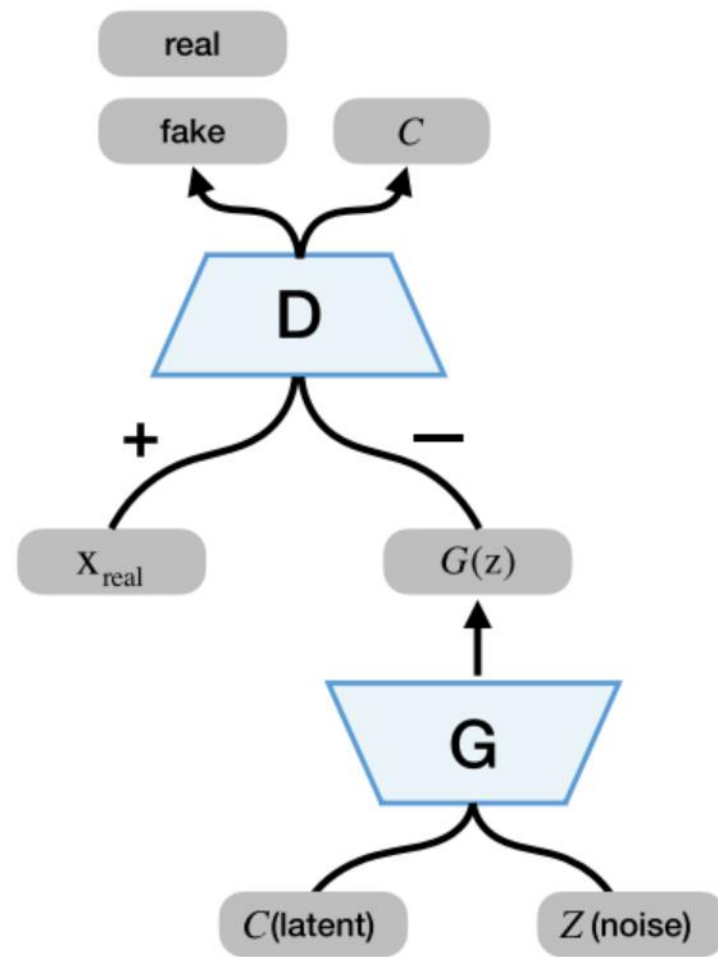


图 InfoGAN的结构

2. GAN的理论的实现模型

21

GAN的衍生模型

(4) WGAN --定义了明确的损失函数，对 G&D 的距离给出了数学定义，较好地解决了训练坍塌问题。




图 WGAN的结构

2. GAN的理论的实现模型

22

GAN的衍生模型

(5) EBGAN--基于能量的生成式对抗网络，从能量模型角度给出了解释。

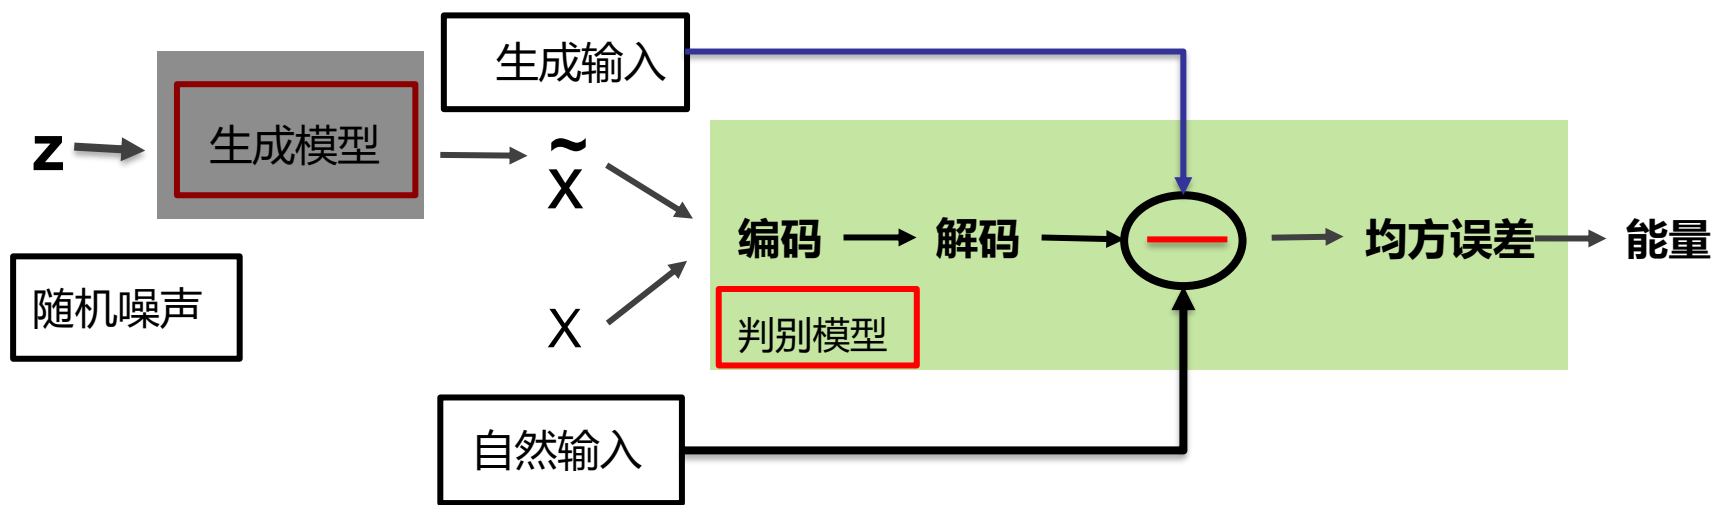


图 EBGAN的结构

2. GAN的理论的实现模型

23

GAN的衍生模型

(6) Improved GAN--改进生成式对抗网络, 提出了使模型训练稳定的五条经验。

- a.特征匹配 (feature matching)
- b.最小批量判断 (minibatch discrimination)
- c.历史平均 (historical averaging)
- d.单边标签平滑 (one-sided label smoothing)
- e.虚拟批量正则 (virtual batch normalization)

3. GAN的应用

24

01 生成式深度学习简介

02 **GAN**的理论与实现模型

03 **GAN** 的应用

04 **GAN**的思考与前景

3. GAN的应用

25

作为一个具有 “无限” 生成能力的模型, GAN的直接应用就是建模, 生成与真实数据分布一致的数据样本, GAN 可以用于解决标注数据不足时的学习问题。

其可以应用于:

- 图像和视觉领域
- 语音和语言领域
- 其他领域

3. GAN的应用

26

图像和视觉领域

GAN 能够生成与真实数据分布一致的图像。一个典型应用是利用 GAN 来将一个低清模糊图像变换为具有丰富细节的高清图像。

用 VGG 网络作为判别器，用参数化的残差网络表示生成器，实验结果如图所示，可以看到 GAN 生成了细节丰富的图像。



图 基于GAN的图像生成示例

3. GAN的应用

27

语音和语言领域

- a. 用 GAN 来表征对话之间的隐式关联性，从而生成对话文本。
- b. 用 CNN 作为判别器, 判别器基于拟合 LSTM 的输出，用矩匹配来解决优化问题；在训练时，和传统更新多次判别器参数再更新一次生成器不同，需要多次更新生成器再更新 CNN 判别器。 SeqGAN 基于策略梯度来训练生成器。
- c. 用GAN 基于文本描述来生成图像，文本编码被作为生成器的条件输入，同时为了利用文本编码信息，也将其作为判别器特定层的额外信息输入来改进判别器，判别是否满足文本描述的准确率。

3. GAN的应用

28

其他领域

除了将 GAN 应用于图像和视觉、语音和语言等领域，GAN 还可以与强化学习、模仿学习等相合。

a. 有人提出用MaIGAN 帮助检测恶意代码，用 GAN生成具有对抗性的病毒代码样本，实验结果表明基于 GAN 的方法可以比传统基于黑盒检测模型的方法性能更好。

b. 也有人提出了一个扩展 GAN 的生成器，用判别器来正则化生成器而不是用一个损失函数，用国际象棋实验示例证明了所提方法的有效性。

4. GAN的思考与前景

29

01 生成式深度学习简介

02 **GAN**的理论与实现模型

03 **GAN** 的应用

04 **GAN**的思考与前景

4. GAN的思考与前景

30

- GAN的优点和意义
- GAN的缺陷
- GAN的发展前景

4. GAN的思考与前景

31

GAN的优点和意义

(1) GAN 对于生成式模型的发展具有重要的意义。

a. GAN 作为一种生成式方法，有效解决了可建立自然性解释的数据的生成难题。

b. GAN的训练过程创新性地将两个神经网络的对抗作为训练准则并且可以使用反向传播进行训练，大大改善了生成式模型的训练难度和训练效率。

c. GAN 在生成样本的实践中，生成的样本易于人类理解。

(2) GAN 除了对生成式模型的贡献，对于半监督学习也有启发。

GAN的缺陷

GAN 虽然解决了生成式模型的一些问题，并且对其他方法的发展具有一定的启发意义，但是 GAN并不完美，它在解决已有问题的同时也引入了一些新的问题。

(1) GAN 优化过程存在不稳定性，很容易陷入到一个鞍点或局部极值点上，即“崩溃模式现象”。

(2) GAN 作为以神经网络为基础的生成式模型，存在神经网络类模型的一般性缺陷，即可解释性差。

(3) GAN 模型需要提高延展性，尤其在处理大规模数据的时候。

4. GAN的思考与前景

33

GAN的发展前景

瑕不掩瑜，GAN 的研究进展表明它具有广阔的发展前景。

如WGAN 彻底解决了训练不稳定问题，同时基本解决了崩溃模式现象。未来研究方向可以是：

- (1) 如何彻底解决崩溃模式并继续优化训练过程。
- (2) 关于 GAN 收敛性和均衡点存在性的理论推断。
- (3) 如何将GAN 与特征学习、模仿学习、强化学习等技术更好地融合，开发新的人工智能应用或者促进这些方法的发展。

1. 江苏师范大学, 申亚博老师课件
2. PyTorch深度学习: 基于PyTorch, 机械工业出版社, 吴茂贵等, 2019年出版
3. Andrew Ng, <http://www.deeplearning.ai>
4. https://blog.csdn.net/longxincheng_ml/article/details/86533005

谢谢!

